JOBLANDERS · VOICE AI · DOCUMENTO MAESTRO UNIFICADO

Voice Agents — Master Playbook

Versión unificada de los tres documentos de investigación: el **Playbook Outbound**, el **Blueprint Inbound Premium** y la **Spec Técnica Inbound**. Un solo stack, dos casos de uso (outbound ventas/recruiting y recepcionista inbound), y todos los trucos que separan un robot de una persona. Julio 2026.

Stack cascaded BYOK

Router por turno

⚡ <700–800 ms voz-a-voz

Trucos de humanidad

⚖ Compliance EU

Evaluación continua

Índice

1. Resumen ejecutivo — el stack de referencia
2. La decisión arquitectónica: cascaded vs speech-to-speech
3. Arquitectura unificada (con router por turno)
4. Selección de modelos capa por capa
5. Router coste-consciente por turno
6. Presupuesto de latencia, milisegundo a milisegundo
7. Turn-taking y barge-in: sistema de 3 capas
8. Máxima humanidad: 7 factores + 13 trucos
9. Caso inbound: flujo de triaje y warm transfer
10. Tools e integraciones (MCP a JoblandersOS)
11. Compliance EU: outbound vs inbound
12. Costes por minuto

13. Evaluación, testing y métricas de éxito
15. Pitfalls que muerden a los equipos de voz
14. Roadmap de implementación
16. Bottom line

1. Resumen ejecutivo — el stack de referencia

Decisión central (válida para outbound e inbound): pipeline **cascaded BYOK** — Twilio → LiveKit Agents → Deepgram Flux → LLM → Cartesia — en lugar de un modelo speech-to-speech monolítico. La innovación no está en cambiar de stack a mitad de llamada, sino en **enrutar solo el cerebro por turno**: un modelo rápido y barato (Gemini Flash / Claude Haiku) para los turnos rutinarios (~70–90%) y un modelo premium (Claude Sonnet) para los difíciles, sobre un único transporte de audio con la misma voz clonada de marca.

Esto te da: (a) la voz de marca en el 100% de la llamada, (b) tool-calling contra JoblandersOS/CRM vía MCP, (c) latencia estable <700–800 ms voz-a-voz, y (d) coste medio bajo y transparente.

OÍDOS (STT)

Deepgram Flux

Fin-de-turno integrado, <300 ms, multilingüe ES/IT.

CEREBRO

Flash ↔ Claude ↔

Router por turno; humano como tercera rama.

VOZ (TTS)

Cartesia / Hume

Voz clonada de marca, ~40–90 ms TTFA.

RAILS

LiveKit + Twilio

Orquestación con SIP y MCP nativos.

2. La decisión arquitectónica: cascaded vs speech-to-speech

① Cascaded pipeline — el elegido

Etapas separadas STT → LLM → TTS que tú conectas. Más piezas móviles, pero controlas cada una.

- **Voz propia / clonada de marca** (Cartesia), idéntica en ES e IT
- **Cualquier LLM** — swap Claude/Gemini/Groq libremente, y routing por turno
- **Tool-calling completo + knowledge base** contra JoblandersOS
- Transparencia total en logs/QA y control fino del endpointing
- Latencia algo mayor que S2S, pero dentro de presupuesto

② Speech-to-speech (S2S)

Un solo modelo de audio nativo (p. ej. OpenAI Realtime, Gemini Live). Latencia mínima e interrupción nativa.

- **Solo voces preset** — sin clonación de voz de marca
- Soporte débil de knowledge base y datos propios en modo realtime
- El cerebro va soldado al stack: sin routing por turno
- Latencia absoluta más baja e interrupciones muy naturales

Veredicto: como la **voz clonada de marca** y el **tool-calling a tus propios datos** son core para JobLanders, ve **cascaded** en ambos casos de uso. S2S queda en el radar solo como A/B independiente para un caso genérico de ultra-baja latencia — nunca como rama del router a mitad de llamada (cambia toda la arquitectura, pierdes la voz clonada y metes un *seam* audible).

3. Arquitectura unificada (con router por turno)

Un voice agent es un loop de baja latencia. Todo el viaje — desde que la persona deja de hablar hasta el primer audio de tu respuesta — es tu **latencia voz-a-voz**, y todo el stack se optimiza para encogerla. Un solo transporte (LiveKit sobre Twilio); solo cambia el **cerebro** según la dificultad del turno, nunca la arquitectura.



El orquestador es el director: LiveKit conecta la línea telefónica (SIP) al pipeline, hace streaming de resultados parciales entre etapas, decide **cuándo el llamante ha terminado su turno** y gestiona el **barge-in** — parar al agente a mitad de frase cuando le interrumpen. La detección de turno y las interrupciones son lo que hace que suene humano, no la calidad cruda del modelo. Y las **tools van vía MCP**: el mismo tool-layer de JoblandersOS que usan tus otros agentes (Lander, Headhunter) alimenta la voz — una integración, muchos agentes.

4. Selección de modelos capa por capa (julio 2026)

CAPA	PICK	MÉTRICA CLAVE	POR QUÉ / ALTERNATIVA
STT + turno	Deepgram Flux Multilingual PICK	<300 ms mediana · ~$0.0048/min	Fin-de-turno (EoT) integrado en el modelo: ahorra 200–600 ms vs STT+VAD externo y elimina una capa entera. `EagerEndOfTurn` permite precomputar la respuesta. Alt: AssemblyAI Universal-Streaming (precio/volumen), ElevenLabs Scribe v2 (sub-150 ms), Cartesia Ink-Whisper (~$0.00217, single-vendor), Gladia (fuerte en ES/EU).
TTS estándar	Cartesia Sonic 3.x PICK	40–90 ms TTFA · clonación con 10–15 s	Arquitectura SSM (state-space): latencia plana bajo carga donde el transformer TTS se degrada; parada/reinicio limpios para barge-in; ~30–40% más barato que ElevenLabs; 40+ idiomas (ES, IT ✓). Clona una voz profesional y mantenla idéntica entre idiomas.
TTS "premium humano"	Hume Octave 2 / ElevenLabs v3	Baja latencia, máxima expresividad	Control emocional/prosódico y mirroring de sentimiento — para cuando "sonar humano" > ahorrar ms. Ojo: planes estándar de ElevenLabs capan ~15 requests concurrentes. Alt: Inworld (top precio/calidad en benchmarks independientes).

Cerebro rápido	Gemini Flash / Claude Haiku PICK	TTFT ~0.35–0.7 s	El 70–90% de los turnos (saludo, clasificación, FAQ con RAG, captura de datos) son triviales: rápido, barato y streamed. Haiku si prima el tool-calling; Groq/ Cerebras si necesitas exprimir ms con modelos abiertos.
Cerebro premium	Claude Sonnet + tools PICK	Function-calling top	Objeciones, quejas, negociación, ambigüedad, multi-tool. Tono natural en ES, sigue instrucciones de persona sin romperse. Alt: GPT-5.x equivalente — elige por eval propia.
Orquestador	LiveKit Agents PICK	Turn-detection semántico	MCP nativo + SIP nativo + barge-in gestionado + plugins para todo el stack = mínimo glue code. Alt: Pipecat (v1.0) para máximo control y composabilidad, más DIY en telefonía.
Telefonía	Twilio SIP → Telnyx a escala	por minuto	Twilio ya lo conoces: camino más rápido a llamadas reales, SIP REFER para transferencias, grabación. Telnyx (red carrier-owned): menor latencia y coste cuando crezca el volumen — A/ B al escalar.

> **Regla de oro:** nada de modos "reasoning/thinking" en la ruta de la llamada — el TTFT se dispara a varios segundos y mata la conversación. Turnos en vivo solo en tiers rápidos/no-reasoning; el razonamiento profundo se reserva para trabajo asíncrono.

5. Router coste-consciente por turno

El router es un componente de lógica (~40 ms sobre el texto ya transcrito, no un modelo extra en el camino crítico) que decide, **antes de cada turno del agente**, qué cerebro responde. Ambos modelos comparten el mismo historial, el mismo system prompt de persona y las mismas tools — cambiar de modelo es invisible para el usuario porque la voz nunca cambia. Y la tercera rama no es otro modelo: es una **persona**.

```
# Router: corre en <40 ms, sin latencia añadida perceptible
def route(turn, ctx):
    if ctx.sentiment < -0.4 or ctx.intent in HIGH_STAKES:
        return "humano"          # queja fuerte, cancelación, legal, prensa
    if turn.complexity > 0.6 or turn.planned_tools > 1 or turn.escalate_requested:
        return "claude_sonnet"   # matiz / negociación / multi-tool
    if ctx.consecutive_calm_turns >= 2:
        return "gemini_flash"    # desescalado con histéresis
    return ctx.current_model      # evita ping-pong entre modelos
```

Señales de escalado (rutina → premium → humano)

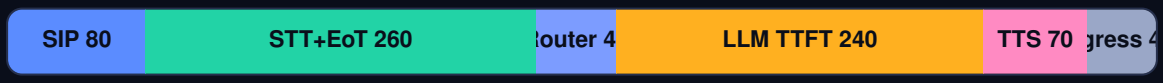
SEÑAL	DETECCIÓN	EJEMPLO
Intent sensible	Lista fija: queja, cancelación, precio/ negociación, legal, prensa	"Quiero hablar de la factura que me habéis cobrado mal"
Frustración / emoción	Heurística sobre texto + señales prosódicas del STT; si sube a mitad de llamada, el router promociona *sin esperar* a que el cliente lo pida	Usuario que repite lo mismo por 2ª vez alzando la voz
El modelo barato levanta la mano	Flash tiene una tool `escalate_turn()` que llama si no está seguro	Pregunta ambigua fuera de las FAQ
Turno multi-tool	El plan requiere >1 llamada a herramienta encadenada	

		"Cámbiame la cita y de paso mira si mi ticket está resuelto"
Fallo de comprensión repetido	2–3 turnos seguidos con reformulación → premium, luego humano	—

Desescalado: tras 2 turnos tranquilos consecutivos gestionados por el premium, el router devuelve el control a Flash. Histéresis simple para evitar ping-pong.

6. Presupuesto de latencia, milisegundo a milisegundo

Por encima de ~800 ms el humano nota la pausa; por encima de ~1,5 s la conversación se siente rota. Objetivo: **p50 <700 ms, p95 <1.100–1.500 ms** voz-a-voz. Presupuesto de un turno normal (cerebro rápido):



SIP ingress/jitter ~80 ms · Flux STT + fin-de-turno ~260 ms · Router ~40 ms · LLM time-to-first-token ~240 ms · Cartesia TTFA ~70 ms · Playback egress ~40 ms

El truco que rompe el presupuesto: solapamiento

Con `EagerEndOfTurn` el LLM **empieza a generar antes** de confirmar el fin de turno (generación especulativa: si el cliente sigue hablando, se cancela). Router y TTS arrancan en paralelo, y el TTS recibe la respuesta frase a frase, no completa. La latencia *percibida* baja de ~730 ms encadenados a **~450–550 ms reales** porque las etapas se

Dónde se pierde de verdad

- El salto del LLM a una región cloud lejana
- El handoff SIP↔CPaaS (uno de los mayores contribuidores ocultos)
- Fix: región EU para todo el stack (LiveKit EU, endpoints EU), co-locar inferencia con la ruta de la llamada, streaming en cada etapa
- Mide por capa y optimiza el salto mayor primero

pisan. Suma **prompt caching** del system prompt.

7. Turn-taking y barge-in: sistema de 3 capas

La sensación de humanidad no viene de la calidad cruda del modelo — viene de **cuándo** habla y de **que se calle** cuando le interrumpes. El barge-in ocurre en ~1 de cada 5 llamadas y es el factor más decisivo.

CAPA 1 · ACÚSTICA

VAD

Silero de base puntúa el audio entrante mientras el agente habla. Detecta que alguien empezó a hablar.

CAPA 2 · ENDPOINTING

Boundary

Decide el límite del enunciado. Adaptativo por contexto: umbral corto (~120 ms) tras un sí/no, largo (~380 ms) tras pregunta abierta.

CAPA 3 · SEMÁNTICA

Turn model

El transformer de LiveKit (o smart-turn de Pipecat) juzga si el *pensamiento* está completo. La capa que se siente humana.

Barge-in con gracia

Parar en **<150 ms** al ser interrumpido (flush inmediato del buffer TTS) — pero con un **periodo de gracia ~200 ms** para no cortarse por una tos, un "ajá" o ruido de fondo. Distinguir *backchannel* ("sí, sí…") de *interrupción real* es lo que evita el ping-pong nervioso.

Tras la interrupción

- Re-escucha y reanuda el contexto sin repetirlo todo
- Reanudar desde la **idea**, no desde la palabra cortada
- El estado de conversación marca la frase como "no terminada de decir"

- Chunkear el TTS a límites de cláusula hace posible la parada limpia

8. Máxima humanidad: 7 factores + 13 trucos

La humanidad percibida no viene de un modelo mágico; es la suma de detalles, ordenados por impacto:

#	FACTOR	CÓMO SE IMPLEMENTA	IMPACTO
1	**Latencia voz-a-voz <800 ms**	Streaming extremo a extremo; generación especulativa; TTS frase a frase.	Crítico
2	**Endpointing semántico**	Flux decide el fin de turno por significado, no por silencio. Elimina cortes prematuros y pausas incómodas.	Crítico
3	**Barge-in real**	TTS cancelado en <150 ms; estado de conversación consistente.	Crítico
4	**Voz clonada premium**	Cartesia Sonic con voz de marca; prosodia emocional por SSML/tags según el estado de la llamada.	Crítico
5	**Backchannels y fillers**	"Ajá", "claro", "un segundo que lo miro…" durante tool-calls y escuchas largas. Cubre la latencia de las herramientas.	Alto
6	**Variabilidad y micro-imperfección**	Nunca repetir el mismo saludo dos veces; disfluencias sutiles; ritmo variable. Prompt + pool de variantes.	Alto
7	**Memoria y continuidad**	Lookup por caller-ID contra el CRM antes de descolgar: "¡Hola de nuevo, María!".	Alto

Los 13 trucos concretos

- **Backchannels en vivo.** "ajá", "ya", "vale" inyectados mientras el cliente da un turno largo — señal de que escuchas.
- **Filler de latencia.** "déjame mirar eso un segundo…" para tapar un tool call (>600 ms → nunca silencio). Empieza a hablar *antes* de tener el dato.
- **Token de acuse inmediato.** Un "vale" en <300 ms mientras se genera el resto → cero silencio muerto.
- **Prosodia dinámica.** SSML/emoción: bajar ritmo en datos sensibles, subir energía en ventas.
- **Mirroring de sentimiento.** Cliente frustrado → tono más calmado y frases cortas.
- **Respiraciones y micro-pausas.** Silencios de coma reales; no un muro de palabras.
- **Uso del nombre con moderación.** Una vez al inicio y en el cierre — más suena a call-center.
- **Frases de recuperación ASR.** "perdona, no te he pillado bien, ¿me lo repites?" en vez de silencio o error.
- **Endpointing por contexto.** Umbral corto tras un sí/no, largo tras pregunta abierta.
- **Comfort noise sutil.** Ruido de sala mínimo para que la línea no suene "muerta" entre turnos.
- **Reanudar por idea, no por palabra.** Tras una interrupción, retomar el *concepto*, no la sílaba cortada.
- **Disfluencias con MUCHA moderación.** Un "eh…" ocasional humaniza; abusar irrita. Medir en eval.
- **Entonación de cierre de turno + cierre cálido.** Bajada tonal al devolver la palabra; nunca colgar en seco — resumir y decir qué pasa ahora.

> **Anti-truco:** no exageres las imperfecciones. Un bot con demasiados "eh…" o backchannels forzados cae en el *uncanny valley* y pierde confianza. Todo se calibra con A/B en eval, no a ojo. **Regla de oro:** un agente con 600 ms de latencia y buen endpointing con una voz "buena" suena más humano que una voz espectacular con 1,5 s de latencia. Invierte primero en el tiempo, después en el timbre.

9. Caso inbound: flujo de triaje y warm transfer

El caso outbound (ventas/recruiting ES+IT) usa el stack tal cual, con el bloque completo de compliance de la sección 11. El inbound (recepcionista + resolutor) añade la máquina de estados de triaje. Ventaja: inbound elimina los bloqueadores legales de outbound (registros de opt-out, consentimiento para llamar) — puedes lanzar semanas antes. El riesgo se traslada de "legal" a "producto": que el filtrado sea correcto y suene humano.

```
1. RING      → caller-ID lookup en CRM (¿cliente? ¿candidato? ¿ya llamó?)
2. DESCUELGA (<2 tonos) → saludo variable + AVISO DE IA + aviso de grabación
     "JobLanders, buenos días. Soy Alba, la asistente virtual. Esta llamada
      se graba para mejorar el servicio. ¿En qué puedo ayudarte?"
3. ESCUCHA ABIERTA (no menú, no "pulse 1") → clasifica en el primer turno:
     ├─ VENTA ———  ¿lead nuevo? → cualifica (nombre, empresa, necesidad, urgencia)
     │             ├─ caliente + horario comercial → WARM TRANSFER a ventas
     │             └─ frío o fuera de horario → agenda callback + resumen a CRM
     ├─ SOPORTE ——  ¿resoluble? (FAQ, estado, horarios, datos) → RESUELVE él mismo (v2)
     │             ├─ resuelto → confirma, ofrece algo más, despide
     │             └─ no resoluble → crea ticket + WARM TRANSFER a soporte
     ├─ OTRO ————  (proveedores, RRHH, prensa) → recado estructurado + ticket
     └─ SPAM ————  robocalls/comerciales → despedida educada firme, cuelga, marca número
4. CIERRE    → resumen automático de la llamada a CRM + Slack del equipo
```

V1 · RECEPCIONISTA

Cualifica y enruta a humano con contexto. Bajo riesgo, sin alucinación posible sobre datos. **Lanza esto primero.**

V2 · RESOLUTOR

Resuelve casos simples solo (FAQ/RAG, estado, callbacks). Más tools y guardrail duro: **responde solo desde tool calls, nunca adivina** precios ni datos.

Reglas de conversación (van al system prompt)

Una sola pregunta por turno. Respuestas de máximo 2 frases salvo explicación. Confirmar datos críticos repitiéndolos ("Te llamo entonces al seis-uno-dos…, ¿correcto?"). Nunca inventar: si no sabe, lo dice y transfiere o toma recado. Nunca prometer precios ni condiciones — eso siempre es transfer a ventas. Si el

usuario pide hablar con una persona, transferir sin resistirse (máximo un intento suave de resolver).

Warm transfer con whisper summary — el detalle que marca la diferencia

1. El agente anuncia: "Te paso con el equipo de ventas, un momento — no te preocupes, ya les cuento yo lo que me has dicho para que no lo repitas."
2. Pone al llamante en espera con música suave y llama al humano por SIP (REFER).
3. Whisper summary: antes de unir las patas, el humano oye ~10 segundos de resumen TTS: "Llama María García, de Acme, interesada en el plan empresa para 15 vacantes, urgencia alta, ya es cliente de la versión gratuita."
4. Se unen las llamadas. En paralelo, el resumen escrito (+ intención + datos + sentimiento) llega por Slack/CRM al agente humano. Cero "¿me lo repite?".
5. Fallback: si nadie contesta en 25 s → el agente recupera la llamada, se disculpa, ofrece callback con hora concreta y crea la tarea. 100% de transferencias fallidas recuperadas.

10. Tools e integraciones (MCP a JoblandersOS)

```
# Servidor MCP compartido — el mismo que Lander / Headhunter / chat / WhatsApp
buscar_contacto(telefono)      → {id, tipo:candidato|empresa, nombre, canal_previo}
estado_cuenta(contacto_id)     → {plan, facturas_pendientes, ticket_abierto?}
search_kb(query)               → RAG sobre FAQ, planes, políticas, horarios
consultar_precio(servicio)     → {precio, moneda, condiciones}   # v2 / outbound
buscar_candidatos(perfil)      → matching de candidatos           # outbound recruiti
get_ticket_status(id|phone)    → estado de tickets de soporte
crear_ticket(contacto_id, tema, resumen, prioridad) → {ticket_id}
check_team_availability(team)  → ¿hay alguien libre en ventas/soporte ahora?
transferir_a_humano(cola, resumen, sentimiento)     → {ok, wait_estimate}
agendar_callback(contacto_id, franja)               → {ok, cuando}
check_registro_optout(telefono)→ Lista Robinson / Opposizioni     # outbound, obligat
escalate_turn()                → el modelo barato cede el turno al premium
end_call(reason)               → cierre limpio con disposición registrada
```

Guardrails de tool

- **Nunca inventar** precio/estado — si no hay tool result, decir "lo confirmo con una persona"
- Timeout de tool → filler humano + fallback a humano
- Toda escritura (ticket, callback) confirmada verbalmente antes de ejecutar
- Streaming tool calls: hablar mientras se consulta — "estoy viendo tu cuenta…" en paralelo al fetch

Por qué MCP

- Una integración sirve voz, chat y WhatsApp
- Memoria cross-canal gratis: la llamada "sabe" que este número habló ayer por WhatsApp
- Versionado y permisos centralizados
- Function-calling fiable > IQ crudo para voz

11. Compliance EU: outbound vs inbound

Tres regímenes se cruzan: el **EU AI Act** (transparencia), **GDPR/ePrivacy** (consentimiento y tratamiento de voz) y los **registros nacionales de exclusión**. Para outbound es un *bloqueador de lanzamiento*; para inbound es ligero pero no opcional.

EU AI ACT · ART. 50

Disclose IA

Desde **ago 2026**: decir claramente, al **inicio** y en el idioma de la llamada, que se habla con una IA.

GDPR / EPRIVACY

Consentimiento + base

Llamadas de marketing a particulares: consentimiento. Exenciones B2B solo con relación previa documentada / interés legítimo. Aviso de grabación + base legal + retención

TECHO DE SANCIÓN

€15M / 3%

Incumplir Art. 50: hasta €15M o el 3% de la facturación global anual — más la

Alternativa no-audio (SMS/chat) disponible. Aplica a outbound e inbound.	definida. Minimización de datos, endpoints EU y DPA firmado con cada proveedor (Deepgram, Cartesia, Google, Anthropic, Twilio, LiveKit).	exposición GDPR aparte.

Outbound — gates duros por país

- **España (AEPD/LOPDGDD):** screening obligatorio contra la **Lista Robinson**; la lectura de la AEPD de "automatizado" probablemente incluye llamadas conducidas por IA aunque un humano inicie la conexión; guidance específica sobre transcripción de voz por IA.
- **Italia:** registro y scrubbing contra el **Registro Pubblico delle Opposizioni** (móviles y fijos) antes de llamar; exenciones B2B estrechas.
- Build-in en el agente: (1) apertura con disclosure en ES/IT, (2) check de registro + consentimiento como tool **que el agente no puede saltarse**, (3) honor instantáneo de "no quiero / non voglio" con logging del opt-out, (4) fallback SMS/chat paralelo.

Inbound — ligero pero innegociable

- Desaparecen: Lista Robinson / Opposizioni, consentimiento para llamar, scrubbing pre-llamada
- **Disclosure de IA** en el primer turno + **aviso de grabación** (con variante sin grabación → `registrar_optout`)
- **Escape a humano** siempre disponible; honrar "no quiero IA" al instante → transferir
- Verificación básica de identidad antes de leer datos de cuenta; nunca confirmar datos de otra persona
- Límite de duración (~10 min) y de bucles (3 fallos de comprensión → transfer); detección de menores/situaciones sensibles → transfer inmediato
- Registro completo: audio, transcripción, modelo usado por turno, tools llamadas, disposición final

No es asesoría legal — validar con abogado antes de marcar/atender números reales. Reglas y enforcement siguen evolucionando durante 2026.

12. Costes por minuto

COMPONENTE	COSTE / MIN APROX.	NOTA
Telefonía (Twilio/ Telnyx)	€0,010–0,015 inbound · variable outbound	Outbound varía mucho por país destino (ES vs IT, móvil vs fijo); inbound es más barato
STT — Deepgram Flux	~$0,005–0,008	Streaming continuo; alternativa barata: Cartesia Ink-Whisper ~$0,002
TTS — Cartesia (voz clonada)	~$0,03–0,10 / €0,02–0,04	Por caracteres; solo se paga lo que habla el agente (~40% del tiempo); ~30–40% más barato que ElevenLabs
LLM (mixto ~85% Flash / 15% Sonnet)	~$0,005–0,04	El routing por turno es lo que mantiene esto bajo; system prompt + tool schemas suman tokens
Orquestación — LiveKit Cloud	~$0,005–0,01	O autoalojado si el volumen crece
Total outbound (BYOK, sin router)	**~$0,12–0,24/min**	**≈ $0,50–0,80 por llamada de 3,5 min**
Total inbound (BYOK, con router)	**~€0,05–0,10/min**	**vs €0,15–0,30/min (2–3×) de plataformas gestionadas premium**

Watch-outs de escalado: los caps de concurrencia (p. ej. ElevenLabs estándar ~15 requests paralelos) pueden throttlear una campaña de llamadas en silencio — verifica límites antes de un push. Y verifica precios vigentes antes de presupuestar: todos los proveedores los han movido varias veces en 2025–2026.

13. Evaluación, testing y métricas de éxito

La voz falla donde el texto no: mala transcripción, turnos torpes, interrupciones, errores de tool a mitad de frase. Testéalo como si fuera conducción autónoma: **simula miles de escenarios pre-lanzamiento, luego vigila cada llamada real** — cada insight de producción se vuelve el siguiente test case.

SIMULACIÓN

Coval

Fundada por una ex-lead de Waymo; genera miles de escenarios desde pocos casos. Simulación → monitoring → revisión humana como un solo loop.

QA + OBSERVABILIDAD

Cekura

Personas con acentos variados y ruido de fondo; señales de voz: gibberish, interrupciones, latencia, sentimiento. Integra con LiveKit y Pipecat.

MÉTRICAS

Hamming

50+ métricas: precisión ASR, latencia, task success, calidad TTS, guardrails de compliance; ~95% de acuerdo con evaluadores humanos.

WER ES/IT <5% · Turn-taking latency · Time-to-first-word · Task success / booked · % clasificación correcta soporte↔ventas · Barge-in handling · Talk-to-listen ratio · Escalados por sentimiento · Guardrails de compliance · Datos alucinados / tool errors · CSAT post-llamada

Objetivos v1 (inbound)

MÉTRICA	OBJETIVO V1	CÓMO SE MIDE
Precisión de triaje (soporte/venta/otro)	> 95%	Revisión humana de muestra semanal etiquetada
Tasa de contención (resuelto sin humano)	> 40% en soporte (v2)	Disposición final por llamada

Latencia voz-a-voz p95	< 1.100 ms	Telemetría del pipeline por turno
Transferencias fallidas recuperadas	100% con callback	Logs de transfer + tareas creadas
Cuelgues en <20 s	< 8%	Proxy de rechazo al agente
"¿Sabías que era una IA?"	Sorpresa positiva	Micro-encuesta post-llamada opcional

> **Auto-eval de confianza:** el agente marca sus propios turnos de baja confianza para revisión humana → cada llamada mejora el siguiente test case.

14. Roadmap de implementación

FASE 1 · SEMANA 1–2

Prototipo del loop (web audio)

LiveKit Agents + Deepgram Flux + router (Flash/Claude) + Cartesia. Clonar la voz ES de marca. 1 tool vía MCP (`buscar_contacto` / `buscar_candidatos`). Saludo, escucha, clasificación, colgar. Sin teléfono aún.

FASE 2 · SEMANA 2–3

Teléfono + triaje / outbound básico

Twilio SIP trunk → LiveKit (DID inbound o número saliente). Máquina de estados GREET→CLASSIFY→ROUTE. Warm transfer con whisper summary, tickets, callbacks. Disclosure de IA + aviso de grabación. Tune de turn detection y barge-in. Piloto interno: el equipo llama e intenta romperlo.

FASE 3 · SEMANA 3–4

FASE 4 · SEMANA 4+

Humanidad + compliance completo

Backchannels, fillers, mirroring de sentimiento, normalización ES de números/fechas/precios, generación especulativa (EagerEoT), memoria por caller-ID, pool de variantes de saludo. Outbound: check Robinson/ Opposizioni como tool obligatorio + voz/prompts en italiano. Sign-off legal.

Eval, piloto y producción

Coval/Cekura sobre personas, acentos y ruido; suite de ~50 llamadas guionizadas; fix de regresiones. Piloto pequeño con dashboards y humano de guardia, revisión semanal de transcripciones, iteración del prompt. Después: resolutor v2 con guardrails, italiano, y escalar concurrencia.

Plan B — plataforma gestionada (si prima la velocidad): Vapi / Retell / ElevenLabs Agents dan el pipeline entero gestionado y validan el caso de negocio en un día — a ~2–3× el coste por minuto y perdiendo voz clonada, integración profunda de datos, routing y unit economics. Estrategia válida: *prototipo gestionado 1 semana → aprender de llamadas reales → construir el stack propio con esos aprendizajes*. No te quedes ahí si el objetivo es "el agente más humano del mercado": el techo de humanidad lo pones con el stack propio.

15. Pitfalls que muerden a los equipos de voz

- **Modos reasoning en la ruta de llamada.** Segundos de TTFT → conversación muerta. Turnos en vivo solo en tier rápido.
- **Ignorar el barge-in.** 1 de cada 5 llamadas se interrumpe; si el agente habla por encima, es un robot por bueno que sea el timbre.
- **Alucinar precios/datos.** Responder solo desde tool calls. Guardrail duro + eval específico.
- **Números, fechas y precios sin normalizar.** "€1.250" mal pronunciado ("mil doscientos cincuenta euros"), teléfonos por parejas, "IVA", horarios — sin capa de normalización ES/IT, el TTS más humano suena robótico en el primer dato.
- **Caps de concurrencia.** Un pico de llamadas puede throttlear en silencio. Verifica límites del vendor antes.

- **Saltarse disclosure / registros.** Innegociable en la EU desde ago 2026; incrústalo en el agente, no en un checklist.
- **Sin escape a humano.** Un filtro sin salida rápida a persona frustra y quema marca.
- **Benchmarks de vendor.** Los números pico ignoran el comportamiento bajo carga — prueba TU stack en TU región.
- **Abusar de disfluencias.** Demasiados "eh…" → uncanny valley y menos confianza.
- **Grabación y retención sin decidir.** Define desde el día 1 qué grabas, cómo lo comunicas y cuánto lo retienes (GDPR).

16. Bottom line

Construye **un solo pipeline cascaded BYOK** — Cartesia voz clonada, Deepgram Flux oídos con fin-de-turno integrado, Gemini Flash ↔ Claude Sonnet ↔ humano como las tres ramas del router por turno, orquestado por LiveKit sobre tu trunk de Twilio, con tools vía MCP a JoblandersOS. Objetivo <700–800 ms voz-a-voz con generación especulativa.

Orden de lanzamiento: ① recepcionista inbound v1 en español (menos fricción legal, valida el stack) → ② resolutor v2 con guardrails anti-alucinación → ③ outbound ES con el bloque completo de compliance (Robinson, disclosure, consentimiento) → ④ italiano. Evalúa cada llamada desde el día 1: timing > timbre, y todo se calibra con datos, no con intuición.

JobLanders · Voice Agents — Master Playbook Unificado · Julio 2026 · Fusiona: "Voice Agents Playbook" (outbound), "Agente de Voz Inbound Premium — Blueprint v1" e "Inbound Voice Agent — Spec Técnica". Precios y capacidades de proveedores sujetos a cambio — validar antes de contratar. No constituye asesoría legal.